

Lista II: Análise de dados

Estes exercícios devem ser realizados usando funções do `tidyverse`. Será necessário importar dados, combiná-los, modificar e resumir de variáveis e criar algumas visualizações e tabelas. Complementarmente, usar `loops` pode facilitar o trabalho, embora não seja algo necessário. Leia as instruções com atenção antes de começar a escrever o seu código.

Descrição

Nesta lista, seu objetivo será analisar mais de 21 mil artigos científicos publicados em 32 periódicos brasileiros nas áreas de *Sociologia* e *Ciência Política e Relações Internacionais*, indexados no Scimago Jr., entre 2000 e 2025. De quebra, este exercício ajudará você a se familiarizar com os artigos já produzidos sobre seu problema de pesquisa – facilitando o levantamento de materiais para, quem sabe, uma futura revisão de literatura.

Usaremos duas bases de dados na tarefa:

- `artigos.rds`, base com metadados (resumos, títulos, autores e quantidade de citações, etc.) da produção acadêmica desses periódicos de cada período de 2000 a 2025.
- `periodicos_ciencias_sociais.csv`, base com a lista de periódicos analisado e informações adicionais, como os seus nomes, se têm acesso aberto e quartil de impacto da publicação (Scimago Jr).

Tarefas

1. Importação

Carregue a base de periódicos (`periodicos_ciencias_sociais.csv`) e a de dados de artigos (`artigos.rds`). Combine elas em um único `data.frame` usando algum `join` (decidir qual é o melhor a se usar é parte da tarefa). Feito isso, você terá uma única base de dados que contém informações sobre os periódicos (como seus nomes) e sobre os seus artigos (como seus títulos e resumos). Por fim, crie uma nova base de dados (chame ela de `artigos_destaque`) com apenas os artigos publicados em periódicos de maior destaque – para fins deste exercício, assumiremos que estes são os Q1, Q2 e Q3. Todas as demais tarefas devem ser respondidas usando apenas a base `artigos_destaque`.

Dicas:

- Os bancos possuem a variável `issn` em comum, isto é, como variável chave.
- O arquivo de periódicos é um arquivo delimitado por texto, o que significa que é necessário descobrir qual é o delimitador usado para separar colunas para carregá-lo corretamente.

2. Seleção de palavras-chave

Escolha **3 palavras-chave** relevantes para o seu problema de pesquisa. Use essas palavras para filtrar os resumos dos artigos da base `artigos_destaque` e selecione apenas as observações que con-

tenham *pelo menos uma dessas palavras*. Obtenha pelo menos 30 (trinta) trabalhos para prosseguir com a análise, caso contrário tente refazer a sua seleção de palavras-chave.

Dicas:

- Considere todas as variações possíveis de uma palavra-chave para aumentar os retornos ou padronize todos os textos para letras minúsculas. Queremos resgatar qualquer documento que mencione uma das opções, algo do tipo: palavra1 OU palavra2 OU palavra3.
- Para transformar textos em minúsculas, use a função `str_to_lower` do pacote `stringr` do `tidyverse`.
- É possível usar a função `str_detect` do pacote `stringr` do `tidyverse` para verificar se uma palavra-chave está presente em determinada variável de texto. Não esqueça que os dados sobre abstract costumam ter falta de informação (NA), lide com eles para não ter erros no filtro.

3. Evolução ao longo do tempo

Crie uma visualização que reporte de forma sucinta e informativa a produção de artigos dentro do seu tema de pesquisa ao longo do tempo (variável ano). Selecione o tipo de visualização que julgar mais adequado para mostrar a frequência absoluta da produção científica entre 2000 e 2025.

4. Relevância bibliométrica ao longo do tempo

Calcule a quantidade de artigos publicados no seu tema e o total de citações recebidas por esses artigos. Para reportar isso essa informação, agrupe os dados por ano e calcule o total de citações recebidas pelos artigos por ano. Além dessa métrica, calcule a média de citações por artigo para cada ano. Com isso, você terá uma métrica de quantidade de artigos e outra de relevância bibliométrica (citações) ao longo do tempo. Com as duas novas variáveis, crie uma visualização que mostre a evolução da produção. Use cores, formas ou outras camadas de `ggplot2` para deixar seu gráficos mais informativo.

5. Evolução relativa

Nos itens 4 e 5, você calculou a evolução absoluta (isto é, em números brutos) de artigos e citações no seu tema por ano entre 2000 e 2025. Agora, calcule a evolução relativa, ou seja, a proporção de artigos publicados sobre o seu tema em relação ao total de artigos publicados em cada ano (na base `artigos_destaque`). Para isso, você precisará calcular o total de artigos publicados em cada ano (em todos os periódicos e em todos os temas) e depois dividir o número de artigos do seu tema por esse total. Com isso, você terá uma métrica de evolução relativa da produção científica sobre o seu tema ao longo do tempo. Crie uma visualização que mostre essa evolução ao longo dos anos.

6. Produção por periódico

Identifique em quais revistas seu tema mais aparece. Para tanto, calcule o total de artigos acadêmicos sobre seu problema de pesquisa agrupado *por revista*. Feito isso, reporte o resultado em uma tabela contendo as observações apenas dos 4 (quatro) periódicos que mais renderam sobre o tema. A tabela final deve exibir 4 colunas: nome da revista (`revista`), quartil Scimago (`quartil`), total de artigos ali encontrados e número de total de citações recebidas pelos artigos publicados sobre

o tema. Ordene decrescentemente pela quantidade de artigos. O resultado precisa ser uma tabela, e não output de console.

Dicas:

- Crie um `data.frame` contendo apenas as informações necessárias para a construção da tabela final. Depois, basta usar a função `kable` do pacote `knitr` para criar uma tabela formatada.

Entrega

Envie um único arquivo PDF, gerado usando o nosso *template* em quarto, no *Google Classroom*, isto é, não envie scripts ou outros arquivos auxiliares. Certifique-se também de que o código no seu PDF esteja visível trocando `echo = FALSE` por `echo = TRUE` na seguinte linha do *template*, que está perto do início do documento:

```
knitr::opts_chunk$set(echo = FALSE, message = FALSE, warning = FALSE)
```

Cada seção do seu documento (sub-títulos antecidos por `##`) deve conter o código que você escreveu para responder o item correspondente da tarefa. Fique à vontade para escrever texto adicional para explicar o que você fez em cada seção.