

## Lista III: Estatística e amostragem

---

Estes exercícios devem ser realizados usando funções do `tidyverse`. Será necessário importar dados, usar funções para calcular estatísticas descritivas e sortear elementos, além de loops para repetir códigos. Leia as instruções com atenção antes de começar a escrever o seu código.

---

### Descrição

Nesta lista, seu objetivo será gerar e analisar amostras da população de Belford Roxo (RJ). Para tanto, usaremos uma base de microdados de toda a população do município extraída do Censo Demográfico de 2010. A base está salva no arquivo `belford_roxo.Rda` e tem 469313 observações (linhas) e 6 variáveis (colunas). São estas:

- `id`: identificador único de cada pessoa
- `zona_domicilio`: zona de domicílio da pessoa (urbana ou rural)
- `sexo`: sexo da pessoa (conforme registrado no Censo)
- `idade`: idade da pessoa (em anos)
- `renda_mensal`: renda mensal da pessoa (em reais de 2010)
- `cor_raca`: cor ou raça da pessoa (conforme registrado no Censo)

### Tarefas

#### 1. Amostragem aleatória simples

Com a base de microdados de Belford Roxo carregada, extraia uma amostra aleatória simples de 800 pessoas (sem repetição). Calcule a média e o desvio padrão da renda mensal da amostra. Compare esses valores com os da população do município.

*Dicas:*

- Uma forma simples de sortear uma amostra de linhas de um `data.frame` é por meio da função `slice_sample` do `tidyverse`.
- Cada sorteio feito no R gerará resultados diferentes. Para garantir que seus resultados sejam reprodutíveis – isto é, que a cada vez que você compilar seu documento você obterá os mesmos resultados –, podemos usar a função `set.seed` logo no início do código, e.g., `set.seed(12345)`.

#### 2. Tamanho da amostra

Ref faça o exercício anterior, agora com duas novas amostras: uma com 1200 pessoas; e, a outra, com 2400 pessoas. Com esses novos resultados, reporte em uma tabela a comparação dos resultados das suas três amostras; indique o tamanho da amostra nas colunas e a média da renda mensal nas linhas. Sua tabela deve ficar mais ou menos assim:

| Renda | Amostra_800 | Amostra_1200 | Amostra_2400 | Base_completa |
|-------|-------------|--------------|--------------|---------------|
| Media | 1234.56     | 1234.56      | 1234.56      | 1234.56       |

*Dicas:*

- Para criar uma tabela no R é possível usar a função `kable`, do pacote `knitr`, ou `gt` do pacote de mesmo nome.

### 3. Distribuição amostral da média

Agora simule a distribuição amostral da média da renda mensal de Belford Roxo. Para isso, repita o sorteio de 800 pessoas 1000 vezes e calcule a média da renda mensal de cada amostra. Dizendo de outra forma, você precisará sortear 1000 amostras diferentes, cada uma com 800 pessoas sorteadas sem repetição, e calcular a média da renda em cada uma delas.

Ao final do processo, o resultado será 1000 medidas da renda média de Belford Roxo. Por fim, faça um histograma com a distribuição das médias da renda mensal. Adicione uma linha vertical no histograma para indicar a média da renda mensal da população de Belford Roxo calculada a partir da base completa.

*Dicas:*

- Para repetir um código várias vezes, é possível usar um `for` loop do R. Lembre-se de criar um objeto vazio para armazenar os resultados de cada iteração.

### 4. Comparação de renda

Agora crie uma nova amostra de pessoas de Belford Roxo, dessa vez com  $n = 2000$ , e a salve em um objeto chamado `amostra_br`. Com essa amostra, compare a média da renda mensal entre pessoas autodeclaradas brancas e pretas (filtre as demais cores/raças do banco de dados antes de tirar a amostra). Reporte a i) a média da renda mensal e o ii) número de pessoas em cada grupo em uma tabela como a seguinte:

| cor_raca | renda_media | n    |
|----------|-------------|------|
| Branca   | 1234.56     | 1000 |
| Preta    | 1234.56     | 1000 |

### 5. Inferência randomizada

Será que a diferença de renda entre pessoas autodeclaradas brancas e pretas no exercício anterior é sistemática ou, ao contrário, resultado do acaso da amostragem? Para responder a essa pergunta, use inferência randomizada para simular a distribuição nula da diferença de renda entre os dois grupos. O procedimento que você deverá implementar é o seguinte:

- 1) Embaralhe os valores da variável `cor_raca` da amostra `amostra_br`, de forma que a cor/raça de cada pessoa seja trocada aleatoriamente.
- 2) Calcule a diferença de renda média entre os dois grupos (brancos e pretos) usando os valores embaralhados da variável `cor_raca`.

- 3) Repita os passos 1 e 2, por exemplo, 1000 vezes, para obter uma distribuição nula da diferença de renda entre os dois grupos.
- 4) Compare a diferença de renda média observada no exercício anterior com a distribuição nula obtida no passo 3. Use um histograma e `geom_vline` para indicar a diferença de renda média observada no exercício anterior.

O que você conclui a partir dessa comparação?

*Dicas:*

- Para embaralhar os valores de uma variável, você pode usar a função `sample` do R com o argumento `replace = FALSE`. Isso irá, na prática, embaralhar os valores da variável, simulando um processo no qual a cor/raça de cada pessoa é trocada aleatoriamente.

## Entrega

Envie um único arquivo PDF, gerado usando o nosso *template* em quarto, no *Google Classroom*, isto é, *não envie scripts ou outros arquivos auxiliares*. Certifique-se também de que o código no seu PDF esteja visível trocando `echo = FALSE` por `echo = TRUE` na seguinte linha do *template*, que está perto do início do documento:

```
knitr::opts_chunk$set(echo = FALSE, message = FALSE, warning = FALSE)
```

Cada seção do seu documento (sub-títulos antecidos por `##`) deve conter o código que você escreveu para responder o item correspondente da tarefa. Fique à vontade para escrever texto adicional para explicar o que você fez em cada seção.