

Lista 2: Desenho de pesquisa

Davi Athaydes Leite

2026-05-05

Segunda lista de Lego 1. Busquei solucionar as questões utilizando as funções do tidyverse. Uma observação: na segunda questão, primeiro selecionei um conjunto de palavras-chave mais “exato” sobre o tema que escolhi. No entanto, capturei um n artigos muito pequeno. Mudei as palavras-chave e capturei um número maior, entretanto, há alguns artigos que não se relacionam ao tema. Decidi prosseguir, para não comprometer o andamento da lista de exercícios.

1. Importação

Importo os bancos normalmente utilizando funções do *Tidyverse*. O único cuidado a mais foi padronizar a variável-chave `issn` do banco `periodicos_ciencias_sociais`, para o *join*. Ao fim, excluo os bancos que não utilizarei mais do meu *environment* com a função `rm()`.

```
artigos <- readRDS("data/artigos.rds")

periodicos_ciencias_sociais <- read_delim(
  "data/periodicos_ciencias_sociais.csv",
  delim = ";", escape_double = FALSE, trim_ws = TRUE) |>
mutate(
  issn = paste0(substr(issn, 1, 4), "-", substr(issn, 5, nchar(issn)))
) # Padronizo o issn (variável-chave) para ficar igual ao outro banco

artigos_dados <- left_join(artigos,
                           periodicos_ciencias_sociais,
                           by = "issn")

artigos_destaque <- artigos_dados |>
  filter(quartil %in% c("Q1", "Q2", "Q3"))

rm(artigos)
rm(periodicos_ciencias_sociais)

# Excluo os dataframes que não serão utilizados do meu environment
```

2. Seleção de palavras-chave

Primeiro padronizo a variável `abstract` para minúsculo, depois filtro os casos em que pelo menos uma das minhas palavras-chave aparecem. Minha linha de raciocínio foi:

- “transfer” -> Captura “transferências”, “transferência voluntária”;
- “discricionar” -> Captura “discricionário”, “discricionária”, “discricionários”;
- “coaliz” -> Captura “coalizão”, “coalizões”.

```
artigos_selecionados <- artigos_destaque |>
  mutate(abstract = tolower(abstract)) |>
  filter(
    str_detect(
      abstract, paste(c("transfer", "discricionar",
                        "coaliz"), collapse = "|")
    )
  )
```

3. Evolução ao longo do tempo

A partir dos artigos selecionados, verifico o total de artigos por ano. Como temos uma variável de tempo, me pareceu adequado elaborar um gráfico de linhas com $x = \text{Ano}$.

```
artigos_selecionados |>
  group_by(ano) |>
  summarise(total_artigos = n()) |>

  ggplot()+
  aes(x = ano, y = total_artigos)+
  geom_line(color="#818589",
            size=1, alpha=0.9) +

  geom_point(shape=21, color="black", fill="#818589", size=1.5) +
  ylim(0,8)+
  scale_x_continuous(breaks = seq(2001, 2025, 1))+
  labs(x = NULL,
       y = "Total de artigos")+
  theme_minimal(base_family = "ibm_sans")+
  theme(
    axis.text.x = element_text(size = 6, face = "bold",
                                angle = 45, hjust = 1),
    axis.text.y = element_text(face = "bold"),
    axis.title.y = element_text(size = 8, face = "bold"),
    axis.title.x = element_text(size = 8, face = "bold"),
    legend.text = element_text(face = "bold"),
    legend.title = element_text(face = "bold")
  )
```




Figura 1: Total de artigos publicados por ano

4. Relevância bibliométrica ao longo do tempo

Nessa questão, após verificar o total e média de citações, preferi pivotar as colunas para ter os valores de ambas as variáveis em uma coluna. Assim, essa coluna de valores é meu *y* no plot, e a coluna que contém a descrição do valor (que chamei de *metrica*) pode ser um termo para um *fill* ou para um *facet_wrap*. Optei pelas facetas.

```
artigos_selecionados |>
  group_by(ano) |>
  summarise(
    `Total de citações` = sum(citacoes_recebidas),
    `Média de citações` = mean(citacoes_recebidas)
  ) |>
  pivot_longer(
    cols = c(`Total de citações`, `Média de citações`),
    names_to = "metrica"
  ) |>

# Aqui eu decidi pivotar para ter as duas métricas em uma só coluna
# Assim uma coluna é meu x, outra o y, e a outra o termo para o facet_wrap

ggplot()+
  aes(x = ano, y = value)+
  geom_line(size=1, alpha=0.9, color = "#818589")+
  geom_point(shape=21, color="black", fill="#818589", size=1.5) +
  scale_x_continuous(breaks = seq(2001, 2025, 1))+
  scale_y_continuous(breaks = seq(0, 160, 20))+
  labs(x = NULL, y = NULL)+
  facet_wrap(~metrica, nrow = 2)+
  theme_minimal(base_family = "ibm_sans")+

  theme(
    legend.position = "bottom",
    axis.text.x = element_text(size = 6, face = "bold",
                                angle = 45, hjust = 1),
    strip.text = element_text(face = "bold", size = 10),
    axis.text.y = element_text(face = "bold"),
    legend.text = element_text(face = "bold"),
    legend.title = element_text(face = "bold")
  )
```




Figura 2: Número total e médio de citações, por ano

5. Evolução relativa

Aqui eu utilizo o banco total de artigos. A ideia foi criar uma variável *dummy* a partir do meu critério de seleção de artigos do meu tema. Os artigos que não contemplam a condição recebem *NA* nessa variável, que chamei de `artigos_tema`. Com ela, sou capaz de calcular o total geral de artigos e o total de artigos do tema, em um mesmo `summarize()`.

```
artigos_destaque |>
  mutate(
    artigos_tema = if_else(
      str_detect(abstract, paste(c("transfer", "discricionar", "coalizao"),
                                collapse = "|")), 1, NA
    )
  ) |>
group_by(ano) |>
summarise(
  total_artigos = n(),
  total_artigos_tema = sum(artigos_tema, na.rm = TRUE)
) |>
mutate(
  proporcao_artigos = total_artigos_tema/total_artigos
) |>

ggplot()+
aes(x = ano, y = proporcao_artigos)+
geom_line(color="#818589",
          size=1, alpha=0.9)+
ylim(0,0.3)+
scale_x_continuous(breaks = seq(2001, 2025, 1))+
geom_point(shape=21, color="black", fill="#818589", size=1.5)+
labs(x = "Ano", y = "Proporção")+
theme_minimal(base_family = "ibm_sans")+
theme(
  axis.text.x = element_text(size = 6, face = "bold",
                              angle = 45, hjust = 1),
  axis.text.y = element_text(face = "bold"),
  axis.title.y = element_text(size = 8, face = "bold"),
  axis.title.x = element_text(size = 8, face = "bold"),
  legend.text = element_text(face = "bold"),
  legend.title = element_text(face = "bold")
)
```




Figura 3: Proporção de artigos do tema em destaque, por ano

```
# Nessa questão, criei uma variável dummy artigos_tema para representar os artigos do meu tema
# A variável recebe 1 se o abstract do artigo conter algum daqueles termos, e NA caso contrário
# NA caso contrário, para que no mesmo summarise eu possa somar o total de artigos,
# e o total de artigos do tema.
```


6. Produção por periódico

Aqui meu cuidado foi deixar o título das colunas formatado corretamente, para o *output* da tabela. Me incomoda um pouco as margens da tabela acompanharem as margens do texto. Aprenderei a corrigir isso.

```
producao_periodicos <- artigos_selecionados |>
  group_by(revista) |>
  summarise(
    Quartil = unique(quartil),
    `Total de artigos` = n(),
    `Total de citações` = sum(citacoes_recebidas, na.rm = TRUE)
  ) |>
  arrange(-`Total de artigos`) |>
  slice(1:4) |>
  rename(
    Revista = revista,
  )

producao_periodicos |>
  knitr::kable(align = c("l", "c", "c", "c"))
```

Tabela 1: Relação de periódicos que mais publicaram sobre o tema

Revista	Quartil	Total de artigos	Total de citações
Dados	Q2	22	223
Revista de Administracao Mackenzie	Q3	18	136
Sociologias	Q2	10	114
Ambiente e Sociedade	Q2	8	115