

Lista 3: Estatística e amostragem

Davi Athaydes Leite

2027-08-05

Terceira lista de Lego 1. Nesse exercício, busquei utilizar os loops da maneira que o Fernando utiliza nas aulas. As funções do tidyverse foram suficientes para solucionar os problemas. Na última questão fiz comentários mais interpretativos, além da explicação do código. No mais, os gráficos estão bonitos!

1. Amostragem aleatória simples

Começo garantindo a replicabilidade com o `set.seed()`. Importo o banco, extraio uma amostra e calculo a média e sd, reportados em uma tabela. Utilizo o `summarise()` Para calcular as medidas tanto da amostra quanto da população. Utilizo o `kable()` para deixar bonito.

```
set.seed(123)

load("data/belford_roxo.Rda")

amostra_belford_roxo <- belford_roxo |>
  slice_sample(n = 800, replace = FALSE)

amostra_belford_roxo |>
  summarise(
    `$$\bar{x}$$` = round(mean(renda_mensal), 2),
    `$$s$$`      = round(sd(renda_mensal), 2),
    `$$\mu$$`    = round(mean(belford_roxo$renda_mensal), 2),
    `$$\sigma$$` = round(sd(belford_roxo$renda_mensal), 2)
  ) |> knitr::kable(
    caption = "Medidas resumo: Renda mensal de Belford Roxo",
    align   = "cccc"
  )
```

Tabela 1: Medidas resumo: Renda mensal de Belford Roxo

$\bar{x}$	s	μ	σ
335.88	609.37	345.34	663.03

2. Tamanho da amostra

Começo criando um vetor com os tamanhos das amostras para fazer um `loop()`; No loop, itero sobre o tamanho de cada amostra o calculo da média de renda mensal. Depois, junto em uma tabela a média da população que calculei no início e as médias das amostras, e reporto em uma tabela.

```
tamanho_amstras <- c(n800 = 800, n1200 = 1200, n2400 = 2400)

tabela <- belford_roxo |>
  summarise(Renda = "Média",
    Base_completa = mean(renda_mensal, na.rm = TRUE))

for (tam in names(tamanho_amstras)) {
  media_amostra <- belford_roxo |>
    slice_sample(n = tamanho_amstras[tam], replace = FALSE) |>
    summarise("Amostra_{tam}" := mean(renda_mensal, na.rm = TRUE))
}
```

```
tabela <- bind_cols(tabela, media_amostra)
}

tabela |>
  mutate(across(where(is.numeric), \(x) round(x,2))) |>
  knitr::kable(align = c("l", "c", "c", "c", "c"))
```

Renda	Base_completa	Amostra_n800	Amostra_n1200	Amostra_n2400
Média	345.34	379.42	351.09	330.52

3. Distribuição amostral da média


Primeiro faço um dataframe em branco. No loop(), extraio a média de 1000 amostras de 800 casos e atribuo no banco.

```
medias <- tibble()

for (i in 1:1000) {
  media_i <- belford_roxo |>
    slice_sample(n = 800, replace = FALSE) |>
    summarise(media = mean(renda_mensal, na.rm = TRUE))

  medias <- bind_rows(medias, media_i)
}

medias |>
  ggplot(aes(x = media))+
  geom_histogram(bins = 30, fill = "steelblue4", color = "white")+
  geom_vline(xintercept = mean(belford_roxo$renda_mensal),
    color = "red", linewidth = .5, linetype = "dashed")+
  labs(
    x = "Média da Renda Mensal (R$)",
    y = "Frequência",
    caption = "Linha vermelha = Média populacional"
  )+
  theme_minimal(base_family = "lora")
```



4. Comparação de renda

O cuidado aqui foi filtrar as outras cores/raças.

```
amostra_br <- belford_roxo |>
  filter(cor_raca %in% c("Branca", "Preta")) |>
  slice_sample(n = 2000, replace = FALSE)

amostra_br |>
  group_by(cor_raca) |>
  summarise(
    `Renda média` = round(mean(renda_mensal), 2),
    n = n()
  ) |> knitr::kable(align = c("l", "c", "c"))
```

cor_raca	Renda média	n
Branca	386.39	1350
Preta	335.14	650

5. Inferência randomizada

Sobre o código: Faço um objeto com a diferença do resultado do exercício anterior. No `loop()`, o cuidado foi aleatorizar os valores da variável de cor/raça.

A diferença que observamos na amostra do exercício anterior aparece na cauda da distribuição nula, isto é, ela raramente ocorre quando embaralhamos os valores da variável de raça de forma aleatória. A diferença observada aparecer na cauda da distribuição nula nos diz que uma proporção bem pequena das simulações produziram diferença similar, indício de que a diferença entre a renda média entre brancos e pretos não é algo do acaso.

```
observado <- amostra_br |>
  group_by(cor_raca) |>
  summarise(
    renda_media = mean(renda_mensal),
  ) |>
  summarise(dif = diff(renda_media)) |>
  pull(dif)

nulo <- tibble()

for (i in 1:1000) {
  dif_i <- amostra_br |>
    mutate(cor_raca = sample(cor_raca, replace = FALSE)) |>
    group_by(cor_raca) |>
    summarise(renda_media = mean(renda_mensal)) |>
    summarise(dif = diff(renda_media))
  nulo <- bind_rows(nulo, dif_i)
}

nulo |>
  ggplot(aes(x = dif))+
  geom_histogram(bins = 30, fill = "steelblue4", color = "white")+
  geom_vline(xintercept = observado,
             color = "red", linewidth = .5, linetype = "dashed")+
  labs(
    x = "Diferença de Renda Média (Preta - Branca)",
    y = "Frequência"
  ) +
  theme_minimal(base_family = "lora")
```




Figura 2: Distribuição nula da diferença de renda média entre pessoas pretas e brancas.