

Lista 4: Regressão linear

Davi Athaydes Leite

2026-12-06

Lista 4 de Lego 1. Busquei interpretar os resultados dos modelos de acordo com as explicações do Fernando em aula. Na questão 2, incluí um `geom_text` para ilustrar as médias no gráfico de barras, para observar o valor do intercepto do modelo. Na última questão, fiz uso da função `plot_model()`, do pacote `sjPlot`, para fazer um plot que ilustra o efeito das duas variáveis independentes.

1. Regressão linear simples

a)

```
modelo_1 <- lm(valor_recebido_total ~ estadia_em_meses,  
               data = bolsas_internacionais_capes_2012)  
  
bolsas_internacionais_capes_2012 |>  
  ggplot()+  
  aes(x = estadia_em_meses, y = valor_recebido_total)+  
  geom_point(shape = 21)+  
  geom_smooth(method = "lm", se = F, color = "darkgray")+  
  labs(  
    x = "Estadia em meses",  
    y = "Valor recebido total"  
  )+  
  theme_minimal(base_family = "lora")
```




Figura 1: Scatterplot: Valor recebido total e estadia em meses

b)

A constante (intercepto) nos mostra que a reta do modelo, quando $x = 0$, parte do valor $y = -313$. Sabemos que não há interpretação substantiva quanto a isso, pois uma bolsa de 0 meses de tempo de estadia não é plausível. O coeficiente beta de 507.959 nos diz que, para cada mês de estadia, o modelo prevê um aumento de R\$507.95 no valor recebido.

Tabela 1: Coeficientes do modelo 1

	(1)
(Intercept)	-313.989 (97.491)
estadia_em_meses	507.959 (7.249)
Num.Obs.	18 177
R2	0.213
R2 Adj.	0.213
AIC	369 406.7
BIC	369 430.1
Log.Lik.	-184 700.345
RMSE	6262.11

```
modelsummary(modelo_1, float = FALSE)
```

2. Variáveis independentes categóricas

a)

```
modelo_2 <- lm(valor_recebido_total ~ regiao,
               data = bolsas_internacionais_capes_2012)

bolsas_internacionais_capes_2012 |>
  group_by(regiao) |>
  summarise(valor_medio = mean(valor_recebido_total)) |>

  ggplot()+
  aes(x = regiao, y = valor_medio)+
  geom_col(fill = "darkgray", color = "black", width = .8)+
  geom_text(
    aes(label = paste0(round(valor_medio, 2))),
    position = position_dodge(width = .7),
    size = 2.5,
    hjust = -.25
  )+
  ylim(0,7000)+
  coord_flip()+
  labs(
    x = "",
```

```
y = "Valor recebido total (média)"
)+
theme_minimal(base_family = "lora")
```




Figura 2: Média do valor recebido total por região

b)

Incluimos uma variável independente categórica nesse modelo. Por padrão, o R toma uma categoria como referência, e calcula os coeficientes dos valores das categorias em comparação à categoria de base. O intercepto é exatamente a média da categoria de referência, Centro-oeste (5745.22). Os valores dos coeficientes das outras categorias indicam o impacto do pertencimento à outra região no valor da bolsa, em comparação ao valor médio do Centro-oeste. Por exemplo, pertencer ao nordeste representa 284,56 a menos no valor da bolsa. Calculando os t-valores (Valor beta / Erro padrão), vemos que a única região que tem efeito significativo é o norte, que representa 831,67 a menos no valor da bolsa.

```
modelsummary(modelo_2, float = FALSE)
```

Tabela 2: Coeficientes do modelo 2

	(1)
(Intercept)	5745.224 (221.263)
regiaoNordeste	−284.568 (255.682)
regiaoNorte	−831.670 (399.194)
regiaoSudeste	60.069 (232.835)
regiaoSul	−71.615 (246.595)
Num.Obs.	18 177
R2	0.001
R2 Adj.	0.000
AIC	373 747.8
BIC	373 794.7
Log.Lik.	−186 867.913
RMSE	7055.21

3. Relação multivariada

a)

A cada mês adicional de estadia, o valor recebido aumenta em média 508.52, controlando pela região. O t-valor de 70.15, calculado a partir da razão entre o coeficiente beta e o erro padrão, demonstra que este é o preditor mais forte nesse modelo, reforçado também pelo p-valor inferior à 0.001. Calculando essa mesma razão entre Beta e Erro padrão para os outros preditores, a região não parece afetar o valor da bolsa. Comparado ao modelo anterior, por exemplo, o pertencimento a região norte fazia diferença. O controle pelo tempo de estadia corrigiu esse efeito.

```
modelo_3 <- lm(valor_recebido_total ~ regiao + estadia_em_meses,  
              data = bolsas_internacionais_capes_2012)  
  
modelsummary(modelo_3, statistic = c("std.error", "p.value"), float = FALSE)
```

b)

```
library(sjPlot)  
  
plot_model(modelo_3, type = "pred", terms = c("estadia_em_meses", "regiao"))+  
  labs(  
    title = NULL,  
    x = "Estadia em meses",  
    y = "Valor recebido total",  
    color = "Região"  
  )+  
  theme_minimal(base_family = "lora")+  
  theme(legend.position = "bottom")
```

Tabela 3: Coeficientes do modelo 3

	(1)
(Intercept)	−544.466 (215.783) (0.012)
regiaoNordeste	−53.638 (226.833) (0.813)
regiaoNorte	−566.365 (354.135) (0.110)
regiaoSudeste	396.990 (206.598) (0.055)
regiaoSul	172.903 (218.776) (0.429)
estadia_em_meses	508.515 (7.248) (<0.001)
Num.Obs.	18 177
R2	0.214
R2 Adj.	0.213
AIC	369 392.7
BIC	369 447.4
Log.Lik.	−184 689.363
RMSE	6258.33




Figura 3: Valores preditos: Impacto do tempo de estadia no valor recebido, por região